

MAXIME BRONNY
19009314

FOUILLE DE DONNÉES

- CAHIER DES CHARGES -

CLUSTERING D'OFFRES D'EMPLOI PAR FOUILLE DE DONNÉES TEXTUELLES
PROJET DE CLUSTERING NON SUPERVISÉ, REPRÉSENTATION VECTORIELLE ET ANALYSE DE
RÉSULTATS

PRÉSENTATION

Ce cahier des charges présente un projet réalisé dans le cadre du cours de Fouille de données du Master 1 Big Data de l'Université Paris 8. Le travail proposé porte sur le regroupement automatique d'offres d'emploi à partir de leur contenu textuel, dans le but de faire émerger des catégories homogènes sans recourir à des étiquettes prédéfinies.

L'objectif du projet est de mettre en place une démarche simple et réaliste de fouille de données textuelles, comprenant la sélection d'un corpus, le prétraitement des annonces, leur représentation vectorielle, l'application d'un algorithme de clustering puis l'analyse des groupes obtenus.

[HTTPS://GITHUB.COM/CRYZINX](https://github.com/cryzinx)

UNIVERSITÉ
PARIS8
VINCENNES-SAINT-DENIS

1 Contexte et présentation du projet

Ce projet s'inscrit dans le cadre de l'unité d'enseignement Fouille de données du Master 1 Informatique, spécialisation Big Data, à l'Université Paris 8. Le travail porte sur l'application de techniques de fouille de données textuelles à un cas concret : le regroupement automatique d'offres d'emploi en catégories homogènes.

Le marché de l'emploi génère un volume important d'annonces publiées sur différentes plateformes. Ces offres sont souvent décrites par du texte libre, sans catégorisation uniforme. L'idée est d'exploiter des méthodes de clustering non supervisé pour faire émerger des groupes cohérents à partir du contenu textuel des annonces, sans disposer d'étiquettes prédéfinies.

2 Problématique

Comment regrouper automatiquement des offres d'emploi en catégories pertinentes à partir de leur contenu textuel, en utilisant des techniques de clustering non supervisé et de représentation vectorielle des textes ?

3 Objectifs du projet

L'objectif principal est de construire un pipeline simple de fouille de données textuelles permettant de regrouper des offres d'emploi selon leur similarité sémantique. Le projet vise à mettre en pratique les étapes fondamentales de la fouille de données telles que présentées dans le cours : collecte, prétraitement, extraction, analyse des résultats et évaluation.

Plus précisément, le projet cherche à :

- Collecter ou sélectionner un jeu de données d'offres d'emploi exploitable.
- Prétraiter les textes pour les rendre utilisables par des algorithmes de clustering.
- Représenter les documents sous forme vectorielle à l'aide de méthodes adaptées.
- Appliquer un ou plusieurs algorithmes de clustering sur les vecteurs obtenus.
- Analyser les groupes formés et évaluer la qualité du regroupement.

4 Données envisagées

Le jeu de données envisagé est un corpus d'offres d'emploi en anglais, disponible en accès libre. Plusieurs options sont envisageables : des jeux de données publics sur Kaggle (par exemple le dataset *Job Postings* ou *Fake and Real Job Postings*), ou un export de données issues d'une API publique d'emploi.

Le corpus retenu devra contenir au minimum quelques milliers d'annonces, avec au moins un champ textuel exploitable (titre, description du poste, compétences requises). Le volume sera adapté pour rester traitable sur une machine personnelle sans ressources de calcul particulières. Si le jeu de données est trop volumineux, un échantillonnage sera effectué.

5 Méthodes et outils prévus

Le projet sera développé en Python, sous forme de notebooks Jupyter. Les principales bibliothèques utilisées seront les suivantes :

- **pandas** pour le chargement et la manipulation des données.
- **nltk** ou **spaCy** pour le prétraitement textuel : tokenisation, suppression des stop-words, lemmatisation.
- **scikit-learn** pour la vectorisation (TF-IDF), le clustering (K-Means, éventuellement DBSCAN) et les métriques d'évaluation.
- **matplotlib** et **seaborn** pour la visualisation des résultats.

La représentation vectorielle des textes reposera sur TF-IDF, qui est une méthode classique, bien documentée et adaptée à ce type de projet. Si le temps le permet, une comparaison avec une réduction de dimensionnalité par TruncatedSVD ou PCA pourra être envisagée avant le clustering.

L'algorithme principal sera K-Means, avec un choix du nombre de clusters guidé par la méthode du coude et le score silhouette. DBSCAN pourra être testé en complément pour comparer les résultats.

6 Étapes de réalisation

Le projet se déroulera selon les étapes suivantes :

1. **Sélection et exploration des données.** Choix du jeu de données, chargement, exploration statistique du corpus (nombre d'annonces, longueur des textes, répartition).
2. **Prétraitement des textes.** Nettoyage (suppression du HTML résiduel, des caractères spéciaux), mise en minuscules, tokenisation, suppression des stopwords, lemmatisation.
3. **Vectorisation.** Transformation des textes nettoyés en vecteurs TF-IDF. Ajustement des paramètres (nombre maximal de features, seuils de fréquence).
4. **Clustering.** Application de K-Means avec plusieurs valeurs de k . Analyse de la méthode du coude et du score silhouette pour choisir le nombre de clusters. Test optionnel de DBSCAN.
5. **Analyse des résultats.** Inspection des clusters : termes les plus fréquents par cluster, exemples d'annonces représentatives, visualisation en 2D par réduction de dimensionnalité.
6. **Évaluation.** Score silhouette moyen, analyse qualitative de la cohérence des groupes, discussion des limites observées.
7. **Rédaction du rapport.** Synthèse du travail réalisé, présentation des résultats et des conclusions.

7 Livrables attendus

Les livrables du projet seront :

- Un notebook Jupyter documenté, contenant l'ensemble du code et des analyses.

- Un rapport synthétique décrivant la démarche, les résultats obtenus et les conclusions.
- Le jeu de données utilisé ou un lien vers sa source.

8 Contraintes et limites

Le projet est réalisé individuellement, dans un temps limité correspondant à une UE de 3 ECTS. Plusieurs contraintes sont à prendre en compte :

- Le traitement se fera sur une machine personnelle, sans accès à un cluster de calcul. Le volume de données et la complexité des algorithmes seront dimensionnés en conséquence.
- TF-IDF, bien qu'efficace pour ce type de tâche, ne capture pas les relations sémantiques fines entre les mots. Les résultats du clustering dépendront fortement de la qualité du prétraitement.
- Le clustering non supervisé ne garantit pas des groupes interprétables. L'analyse qualitative sera nécessaire pour juger de la pertinence des résultats.
- L'absence d'étiquettes de référence rend l'évaluation quantitative limitée. Les métriques internes (silhouette) donnent une indication, mais ne suffisent pas à valider la pertinence métier des clusters.

9 Conclusion

Ce projet propose une application concrète et réaliste des méthodes de fouille de données textuelles. Le clustering d'offres d'emploi permet de mobiliser les différentes étapes du processus de fouille (collecte, prétraitement, représentation, extraction, évaluation) sur des données réelles. Le périmètre reste volontairement simple pour garantir un travail abouti et bien maîtrisé dans le cadre de cette UE.