

MAXIME BRONNY
19009314

FOUILLE DE DONNÉES

- RAPPORT DE PROJET -

CLUSTERING AUTOMATIQUE D'OFFRES D'EMPLOI
PAR FOUILLE DE DONNÉES TEXTUELLES

PRÉSENTATION

Ce rapport présente un projet réalisé dans le cadre de l'UE Fouille de données textuelles du Master 1 Informatique, spécialisation Big Data, à l'Université Paris 8. Le travail porte sur le regroupement automatique d'offres d'emploi à partir de leur contenu textuel, dans le but de faire émerger des familles de métiers sans utiliser d'étiquettes prédéfinies.

L'objectif de ce projet est de mettre en œuvre une démarche complète de fouille de données textuelles, comprenant la préparation du corpus, le prétraitement des annonces, leur représentation vectorielle, l'application d'un algorithme de clustering, puis l'analyse critique et la validation des résultats obtenus.

[HTTPS://GITHUB.COM/CRYZINX](https://github.com/cryzinx)

UNIVERSITÉ
PARIS8
VINCENNES-SAINT-DENIS

Table des matières

1	Introduction	2
2	Données	2
2.1	Présentation du corpus	2
2.2	Fichiers de validation externe	3
2.3	Données exclues	3
3	Méthodologie	3
3.1	Prétraitement textuel	3
3.2	Vectorisation TF-IDF	4
3.3	Clustering	4
3.3.1	K-Means	4
3.3.2	Comparaison avec DBSCAN	5
3.4	Stratégie d'évaluation	5
4	Résultats	5
4.1	Exploration du corpus	5
4.2	Sélection du nombre de clusters	7
4.3	Clusters obtenus	7
4.4	Validation externe	10
5	Discussion	10
5.1	Analyse critique des résultats	10
5.2	Limites	12
5.3	Pistes d'amélioration	12
6	Conclusion	12

1. Introduction

Ce projet s'inscrit dans le cadre de l'UE Fouille de données textuelles du Master 1 Informatique, spécialisation Big Data, à l'Université Paris 8. Il porte sur un problème concret de traitement automatique de données textuelles : le regroupement d'offres d'emploi en familles de métiers à partir de leur contenu, sans disposer d'étiquettes prédéfinies.

La problématique peut se formuler ainsi : comment faire émerger des catégories professionnelles pertinentes à partir du texte libre d'annonces d'emploi, en mobilisant les étapes classiques de la fouille de données textuelles (prétraitement, représentation vectorielle, clustering non supervisé, évaluation) ?

Le corpus utilisé est un ensemble d'offres d'emploi issues de LinkedIn, contenant environ 124 000 annonces en anglais. L'approche retenue repose sur une représentation TF-IDF des textes suivie d'un clustering K-Means. Une comparaison avec l'algorithme DBSCAN est également réalisée pour évaluer une approche alternative. Les résultats sont validés par croisement avec des métadonnées structurées du dataset (secteurs d'activité et compétences LinkedIn).

L'ensemble du traitement est réalisé en Python 3.12 dans un environnement Jupyter Notebook, en s'appuyant sur les bibliothèques scikit-learn, NLTK, pandas et matplotlib.

Ce rapport présente successivement les données utilisées, la méthodologie mise en œuvre, les résultats obtenus et une discussion critique des forces et limites du projet.

2. Données

2.1 Présentation du corpus

Le corpus provient du dataset *LinkedIn Job Postings* publié sur la plateforme Kaggle [1], qui contient environ 124 000 offres d'emploi rédigées en anglais. Chaque offre comporte un titre de poste et une description complète, deux champs textuels toujours renseignés qui constituent la matière première du clustering. Un champ structuré indique le niveau d'expérience requis, renseigné dans environ 76 % des cas. Ce champ n'est pas utilisé pour le clustering mais sert à la validation croisée des résultats.

Un échantillon aléatoire de 30 000 offres est extrait pour le traitement, ce qui représente environ 24 % du corpus et offre un bon compromis entre couverture statistique et temps de calcul. Les descriptions trop courtes (moins de 100 caractères) sont filtrées. La reproductibilité est garantie par une graine aléatoire fixe.

2.2 Fichiers de validation externe

Le dataset fournit également des fichiers de métadonnées structurées qui permettent de valider a posteriori la qualité des clusters. Des fichiers d'association relient chaque offre à un secteur d'activité LinkedIn et à une catégorie de compétence, avec une couverture supérieure à 98 % dans les deux cas. Ces fichiers ne contribuent pas au clustering. Ils servent uniquement à vérifier, après le regroupement, que les clusters textuels correspondent à des catégories métier réelles.

2.3 Données exclues

Plusieurs fichiers du dataset n'ont pas été retenus. Les fichiers relatifs aux entreprises (`companies.csv`, `company_industries.csv`) ne sont pas pertinents car le clustering porte sur le contenu des offres, pas sur les caractéristiques des employeurs. Les fichiers de salaires (couverture de 29 %) et d'avantages sociaux (couverture de 23 %) ont été écartés en raison de leur couverture insuffisante. Le champ `skills_desc`, qui contient des compétences en texte libre, est vide dans environ 90 % des cas et n'a donc pas été exploité.

3. Méthodologie

3.1 Prétraitement textuel

Le prétraitement est l'étape la plus déterminante pour la qualité du clustering. Pour chaque offre, le titre est concaténé avec la description, puis le texte est nettoyé par un module dédié. Le nettoyage comprend la suppression du HTML résiduel, le passage en minuscules, le retrait des caractères non alphabétiques, la suppression des stopwords anglais et la lemmatisation.

Un traitement spécifique au domaine des offres d'emploi a été ajouté : le retrait du boilerplate juridique. Environ 30 % des descriptions contiennent des blocs de texte standardisés (mentions légales, clauses de non-discrimination) qui ne sont pas discriminants pour le clustering par métier. Sans ce nettoyage, ces formulations récurrentes dominent la représentation TF-IDF et produisent un cluster parasite regroupant les annonces par leur texte juridique plutôt que par leur contenu professionnel. Des expressions régulières et des stopwords spécifiques au domaine ont été utilisés pour supprimer ce bruit.

Après nettoyage, les documents comptent environ 300 tokens en médiane.

3.2 Vectorisation TF-IDF

Les textes nettoyés sont transformés en vecteurs numériques par le `TfidfVectorizer` de scikit-learn. Le choix de TF-IDF repose sur deux arguments : sa simplicité de mise en œuvre et son interprétabilité. Contrairement aux plongements de mots denses (Word2Vec, BERT), TF-IDF produit des vecteurs directement liés au vocabulaire du corpus, ce qui facilite l'analyse des clusters par extraction des termes dominants.

Les paramètres retenus sont résumés dans le tableau 1.

Tableau 1: Paramètres du vectoriseur TF-IDF

Paramètre	Valeur	Rôle
<code>max_features</code>	10 000	Taille maximale du vocabulaire
<code>max_df</code>	0.85	Exclut les termes dans plus de 85 % des documents
<code>min_df</code>	50	Exclut les termes dans moins de 50 documents
<code>sublinear_tf</code>	True	Atténuation de l'effet des fréquences élevées
<code>gram_range</code>	(1, 2)	Unigrammes et bigrammes

La matrice résultante est de dimension $30\,000 \times 10\,000$. Les bigrammes permettent de capturer des expressions composées discriminantes comme *registered nurse*, *data analyst* ou *customer service*.

3.3 Clustering

3.3.1 K-Means

Le nombre de clusters est déterminé en testant les valeurs de k de 2 à 15. Pour chaque valeur, deux indicateurs sont calculés : l'inertie (somme des distances au centroïde, méthode du coude) et le score silhouette moyen, évalué sur un sous-échantillon de 10 000 documents pour limiter le temps de calcul.

La courbe d'inertie décroît de façon quasi continue, sans coude marqué (la baisse totale n'atteint pas 4 % entre $k = 2$ et $k = 15$). Les scores silhouette restent faibles pour toutes les valeurs de k (inférieurs à 0.02) et ne désignent aucun maximum exploitable, ce qui est un comportement attendu en clustering textuel haute dimension. Ni le coude ni la silhouette ne tranchent donc, et le choix final repose entièrement sur l'interprétabilité qualitative : $k = 8$ produit des clusters thématiquement cohérents et identifiables, tandis que des valeurs supérieures fragmentent les groupes en sous-catégories difficilement distinguables.

Le modèle K-Means final est entraîné avec `n_init = 10` (dix initialisations aléatoires pour éviter les minima locaux) et `max_iter = 300`.

3.3.2 Comparaison avec DBSCAN

DBSCAN est testé comme approche alternative basée sur la densité. Cet algorithme ne nécessite pas de spécifier le nombre de clusters à l'avance et peut identifier des points de bruit, ce qui est potentiellement intéressant pour isoler les offres atypiques.

Les données TF-IDF sont d'abord réduites à 50 dimensions par TruncatedSVD, car DBSCAN est sensible à la haute dimension. Quatre valeurs du paramètre epsilon sont testées (0.5, 1.0, 1.5, 2.0) avec `min_samples = 10`. Les résultats montrent que DBSCAN ne produit aucun regroupement exploitable et n'isole aucun point de bruit (0% pour tous les epsilon testés) : avec $\epsilon = 0.5$ il forme trois clusters sans aucun bruit, et dès $\epsilon = 1.0$ un cluster unique absorbe la quasi-totalité des données. La réduction TruncatedSVD à 50 dimensions ne conserve que 13.8% de la variance, ce qui rend les points trop uniformément denses pour que DBSCAN distingue des zones de densité. K-Means est donc retenu comme méthode principale.

3.4 Stratégie d'évaluation

L'évaluation des clusters repose sur trois axes complémentaires : le score silhouette (métrique interne de cohérence), l'interprétation qualitative des termes dominants et des offres représentatives, et la validation externe par croisement avec les métadonnées LinkedIn (secteurs d'activité, compétences, niveaux d'expérience).

Cette approche combinée est nécessaire car le score silhouette seul est peu fiable en clustering textuel haute dimension. Le croisement avec des données structurées indépendantes offre un moyen plus concret de vérifier que les clusters correspondent à des catégories professionnelles réelles.

4. Résultats

4.1 Exploration du corpus

L'exploration du corpus révèle une forte variabilité dans la longueur des descriptions, avec une moyenne d'environ 3 800 caractères et des écarts importants selon les recruteurs. La figure 1 illustre cette distribution.

Après prétraitement, la plupart des documents comptent entre 200 et 400 tokens (figure 2), ce qui confirme que le nettoyage produit des documents de taille suffisante pour la vectorisation.

La répartition des niveaux d'expérience est dominée par les profils Mid-Senior et Entry level, qui représentent ensemble la grande majorité de l'échantillon.




Figure 1: Distribution des longueurs des descriptions avant nettoyage




Figure 2: Distribution du nombre de tokens par document après nettoyage

4.2 Sélection du nombre de clusters

La figure 3 présente la courbe du coude et les scores silhouette pour $k = 2$ à 15. La décroissance de l'inertie ralentit progressivement sans point d'inflexion net, ce qui est courant en clustering textuel. Les scores silhouette sont faibles et non discriminants pour toutes les valeurs de k (tous inférieurs à 0.015, sans maximum exploitable). Ni le coude ni la silhouette ne désignent une valeur de k . Le choix de $k = 8$ repose donc sur l'examen qualitatif des clusters produits pour différentes valeurs, qui montre que $k = 8$ offre le meilleur équilibre entre granularité et interprétabilité.




Figure 3: Méthode du coude (inertie) et scores silhouette pour $k = 2$ à 15


4.3 Clusters obtenus

Le tableau 2 présente le profil des huit clusters obtenus. Chaque cluster est caractérisé par un thème interprétatif déduit des termes dominants, sa taille, son score silhouette moyen et le pourcentage de documents ayant un score silhouette positif.

Tableau 2: Profil des huit clusters obtenus par K-Means ($k = 8$)

Cl.	Thème interprétatif	Taille	Silh.	% pos.
0	Emplois physiques et terrain	703	0.060	100 %
1	Maintenance et technique	4 288	-0.002	49 %
2	Commerce de détail	2 238	0.022	98 %
3	Services généraux (résiduel)	7 579	-0.007	5 %
4	Santé et soins infirmiers	3 760	0.024	99 %
5	Informatique et ingénierie	3 974	0.008	85 %
6	Direction commerciale (niche)	150	0.969	100 %
7	Management et gestion	7 308	0.009	93 %

La figure 4 montre la répartition des tailles. La distribution est déséquilibrée : deux clusters concentrent près de la moitié des offres (cluster 3 avec 7 579 offres et cluster 7 avec 7 308), tandis que le cluster 6 n'en contient que 150. Ce déséquilibre tient à la fois à la structure du marché (les profils généralistes sont plus nombreux) et au comportement de K-Means, qui concentre dans un cluster résiduel les offres sans spécialité nette.

Figure 4: Taille de chaque cluster ($k = 8$)

Parmi les huit clusters, plusieurs présentent une forte cohérence thématique. Le cluster 4 (santé et soins infirmiers) est dominé par les termes *patient*, *care*, *nurse*, *nursing* et *registered nurse*, avec 99 % de scores silhouette positifs. Le cluster 5 (informatique) regroupe les termes *engineer*, *software*, *design*, *system* et *developer*. Le cluster 2 (commerce de détail) est identifié par *store*, *sale*, *retail*, *associate* et *merchandise*.

Le cluster 3 (services généraux) fonctionne comme un groupe résiduel. Ses termes dominants (*work*, *service*, *client*, *team*, *benefit*) sont peu spécifiques, et seulement 5 % de ses documents ont un score silhouette positif. Ce comportement est classique avec K-Means, qui assigne chaque document à un cluster sans possibilité de rejet : les offres qui ne correspondent clairement à aucune spécialité se retrouvent dans le groupe aux termes les plus génériques.

Le cluster 6 appelle une mise en garde : avec seulement 150 offres et un score silhouette anormalement élevé (0.969, contre environ 0.01 ailleurs), il ne correspond pas à une véritable famille de métiers mais à un ensemble de quasi-doublons d'un même employeur (terme dominant *galt*, pour la société J. Galt). Une silhouette aussi élevée, isolée dans un score global de 0.012, est un signal de doublons plutôt que de cohérence métier ; elle découle de l'absence de déduplication du corpus.

Le tableau 3 présente, pour chaque cluster, les titres de postes des annonces les plus proches du centroïde. Ces exemples concrets illustrent la cohérence thématique des regroupements : les offres les plus représentatives de chaque cluster correspondent bien au thème interprétatif identifié.

La figure 5 présente une projection en deux dimensions des clusters par TruncatedSVD. Certains clusters (santé, commerce de détail) forment des groupes visuellement distincts, tandis que d'autres se chevauchent, ce qui est cohérent avec les scores silhouette observés.

Tableau 3: Exemples d'annonces les plus proches du centroïde de chaque cluster

Cl.	Thème	Titres des annonces les plus proches du centroïde
0	Emplois physiques	<i>Store Driver</i> (Advance Auto Parts)
1	Maintenance	<i>Healthcare Facilities Technician</i> (OHSU), <i>Field Service Technician</i> , <i>Manufacturing Maintenance Technician</i>
2	Commerce de détail	<i>Assistant Store Manager</i> , <i>Store Manager</i> (Ross Stores)
3	Services généraux	<i>Software Support Specialist</i> (Storable), <i>Social Worker Care Coach</i> (Humana)
4	Santé	<i>Registered Nurse RN</i> (Banner Health), <i>Ambulatory Care Nurse</i> (NYU Langone), <i>Medical Assistant</i> (Beth Israel Lahey)
5	Informatique	<i>Full Stack Engineer</i> (InfoStride), <i>Software Engineer in Test</i> (VMC Soft Technologies)
6	Direction commerciale	<i>Sales Manager</i> (J. Galt)
7	Management	<i>Strategic Sourcing Manager</i> (Genesys), <i>VP Integrated Solutions Executive</i> (Premier Inc.)




Figure 5: Projection en deux dimensions des clusters par TruncatedSVD

4.4 Validation externe

Le croisement avec les niveaux d'expérience (figure 6) montre des variations de séniorité entre les clusters. Le cluster 7 (management) présente une proportion plus élevée de profils Mid-Senior et Director, tandis que le cluster 2 (commerce de détail) concentre davantage de profils Entry level et Associate. Ces variations confirment que le clustering textuel capture implicitement des différences de niveau professionnel, sans que l'information sur l'expérience ait été utilisée dans le regroupement.




Figure 6: Répartition des niveaux d'expérience par cluster

Le croisement avec les secteurs d'activité LinkedIn (figure 7) fournit une validation plus directe. Les clusters textuels correspondent dans une large mesure aux secteurs déclarés : le cluster 4 est associé au secteur de la santé, le cluster 5 aux technologies de l'information, le cluster 2 au commerce de détail. Cette correspondance entre un regroupement non supervisé basé sur le texte et des catégories définies indépendamment par LinkedIn constitue un signal positif de la qualité des clusters.

Le croisement avec les catégories de compétences (figure 8) confirme et complète cette observation. Chaque cluster bien défini est associé à un profil de compétences cohérent avec son thème interprétatif.

5. Discussion

5.1 Analyse critique des résultats

Les résultats montrent que le pipeline TF-IDF suivi de K-Means parvient à faire émerger des familles de métiers cohérentes à partir du texte libre des offres d'emploi. Sur les huit clusters obtenus, au moins cinq présentent un thème clairement identifiable et validé




Figure 7: Croisement entre les clusters et les dix principaux secteurs d'activité LinkedIn




Figure 8: Croisement entre les clusters et les dix principales catégories de compétences LinkedIn

par les métadonnées LinkedIn : santé, informatique, commerce de détail, management et maintenance technique. Le cluster 0 (emplois physiques) et le cluster 6 (direction commerciale) sont également interprétables, bien que plus spécifiques.

Le score silhouette global (0.012) est faible, mais cette métrique est connue pour être peu adaptée au clustering textuel en haute dimension. La validation externe par les secteurs d'activité et les compétences LinkedIn offre un signal plus fiable et confirme que les clusters correspondent à des catégories professionnelles réelles.

Le principal point faible est le cluster 3 (services généraux), qui rassemble 7 579 offres avec un profil peu spécifique et un score silhouette négatif. Ce cluster absorbe les offres qui ne correspondent clairement à aucune spécialité, ce qui est un comportement attendu de K-Means. Une augmentation du nombre de clusters pourrait fragmenter ce groupe résiduel, mais au risque de diluer les autres clusters bien définis.

5.2 Limites

TF-IDF ne capture pas les relations sémantiques entre les mots : deux offres portant sur le même métier mais rédigées différemment peuvent se retrouver dans des clusters distincts. K-Means impose un nombre fixe de clusters et assigne chaque document à un groupe sans possibilité de rejet, ce qui explique l'existence du cluster résiduel (cluster 3) ; deux clusters ont d'ailleurs une silhouette moyenne négative (clusters 1 et 3). Le corpus n'est pas déduplicqué : il contient des annonces quasi identiques d'un même employeur, ce qui produit des groupes artificiels comme le cluster 6 (doublons de la société J. Galt, silhouette 0.969). Le nettoyage du boilerplate reste par ailleurs incomplet : le cluster 0 demeure dominé par la clause légale ADA (*physical demands*), non couverte par les expressions régulières. Le corpus est enfin entièrement en anglais et le pipeline de prétraitement est spécifique à cette langue.

5.3 Pistes d'amélioration

Plusieurs pistes pourraient améliorer les résultats. L'utilisation de représentations vectorielles denses (Word2Vec, Sentence-BERT) capturerait mieux les relations sémantiques entre les mots. Une réduction dimensionnelle avant le clustering pourrait améliorer la séparation des groupes. Le clustering hiérarchique permettrait d'analyser la structure du corpus à plusieurs niveaux de granularité.

6. Conclusion

Ce projet met en œuvre un pipeline complet de fouille de données textuelles appliqué au regroupement automatique d'offres d'emploi LinkedIn. Le traitement, allant du nettoyage

des données à l'interprétation des clusters, repose sur des méthodes classiques (TF-IDF, K-Means) dont la simplicité et l'interprétabilité sont des atouts dans un contexte de projet universitaire.

Les résultats montrent que cette approche parvient à faire émerger des familles de métiers cohérentes et vérifiables. Le travail illustre également l'importance du prétraitement textuel, en particulier le retrait du boilerplate juridique qui constitue un bruit significatif dans les données d'offres d'emploi, ainsi que la nécessité de croiser métriques quantitatives et analyse qualitative pour évaluer un clustering textuel en haute dimension.

References

- [1] A. Kon, *LinkedIn Job Postings (2023)*, Kaggle. Disponible : <https://www.kaggle.com/datasets/arshkon/linkedin-job-postings>