

MAXIME BRONNY
19009314

FOUILLE DE DONNÉES

- DOCUMENTATION UTILISATEUR -

GUIDE D'INSTALLATION, DE PRISE EN MAIN ET D'UTILISATION
PROJET DE CLUSTERING D'OFFRES D'EMPLOI PAR FOUILLE DE DONNÉES TEXTUELLES

PRÉSENTATION

Cette documentation utilisateur présente un projet réalisé dans le cadre de l'UE Fouille de données textuelles du Master 1 Informatique, spécialisation Big Data, à l'Université Paris 8. Le travail porte sur le regroupement automatique d'offres d'emploi à partir de leur contenu textuel, dans le but de faire émerger des familles de métiers sans utiliser d'étiquettes prédéfinies.

Ce document a pour objectif d'expliquer de manière claire la mise en place et l'utilisation du projet. Il décrit l'environnement nécessaire, l'organisation des fichiers, les données en entrée, le lancement du notebook principal, ainsi que les sorties produites par le pipeline, afin de permettre une prise en main simple et cohérente du projet.

[HTTPS://GITHUB.COM/CRYZINX](https://github.com/cryzinx)

UNIVERSITÉ
PARIS8
VINCENNES-SAINT-DENIS

Table des matières

1	Présentation du projet	3
2	Objectif de l'outil	3
3	Public visé	3
4	Prérequis techniques	4
5	Installation	4
5.1	Création de l'environnement virtuel	4
5.2	Installation des dépendances	4
5.3	Téléchargement des ressources NLTK	5
5.4	Données	5
6	Démarrage rapide	5
7	Organisation du projet	6
8	Utilisation du projet	7
8.1	Lancement du notebook	7
8.2	Déroulement du pipeline	7
8.3	Modification des paramètres	8
9	Description des données en entrée	8
9.1	Fichiers secondaires utilisés pour la validation	8
9.2	Fichiers non exploités	9
10	Description des sorties	9
11	Comment lire les résultats	10
11.1	Tableau récapitulatif des clusters	10
11.2	Graphiques de validation	10
11.3	Score silhouette	10
11.4	Projection 2D	11
12	Exemple de workflow	11
13	Limites et précautions	11
14	Dépannage	12
14.1	Erreur <code>ModuleNotFoundError</code>	12

14.2 Erreur <code>NLTK Resource not found</code>	12
14.3 Erreur <code>FileNotFoundError</code> pour <code>postings.csv</code>	12
14.4 Le notebook est très lent ou plante	12
14.5 Les graphiques ne s'affichent pas	13
15 Conclusion	13

1. Présentation du projet

Ce projet s'inscrit dans le cadre de l'UE Fouille de données textuelles du Master 1 Informatique, spécialisation Big Data, à l'Université Paris 8. Il consiste à regrouper automatiquement des offres d'emploi en catégories homogènes à partir de leur contenu textuel, sans disposer d'étiquettes prédéfinies.

Le corpus utilisé est un ensemble d'offres d'emploi issues de LinkedIn, contenant environ 124 000 annonces en anglais. Le projet met en œuvre un pipeline complet de fouille de données textuelles, depuis le chargement et le nettoyage des données jusqu'au clustering et à l'interprétation des résultats.

L'approche repose sur une représentation vectorielle des textes par TF-IDF, suivie d'un clustering non supervisé par K-Means. Un échantillon de 30 000 offres est utilisé pour le traitement, ce qui offre un bon compromis entre représentativité statistique et temps de calcul.

2. Objectif de l'outil

L'objectif principal est de faire émerger des familles de métiers à partir du texte libre des annonces d'emploi. Le pipeline prend en entrée un fichier CSV contenant des offres d'emploi et produit en sortie un ensemble de clusters thématiques, chacun correspondant à un domaine professionnel identifiable (santé, informatique, commerce, finance, etc.).

Le projet permet également de visualiser la répartition des clusters, d'analyser les termes les plus représentatifs de chaque groupe et de valider les résultats par croisement avec des métadonnées structurées du dataset (secteurs d'activité et catégories de compétences LinkedIn).

3. Public visé

Cette documentation s'adresse aux étudiants et enseignants souhaitant comprendre et reproduire le travail réalisé dans ce projet. Elle suppose une connaissance de base de Python, de l'environnement Jupyter et des concepts fondamentaux du traitement automatique du langage naturel. Aucune expertise avancée en apprentissage automatique n'est requise pour exécuter le pipeline.

4. Prérequis techniques

Le projet a été développé et testé avec Python 3.12 sur un système Linux. Il est compatible avec les systèmes d'exploitation courants (Linux, macOS, Windows) à condition de disposer de Python 3.10 ou supérieur.

Le fichier de données principal (`postings.csv`) pèse environ 500 Mo. Il est recommandé de disposer d'au moins 8 Go de mémoire vive pour exécuter le notebook sans difficulté. Le pipeline complet s'exécute en environ 5 minutes sur une machine personnelle standard.

Les bibliothèques Python nécessaires sont listées dans le fichier `requirements.txt` à la racine du projet. Les principales dépendances sont les suivantes.

- `pandas` (version 2.0 ou supérieure) pour la manipulation des données tabulaires
- `numpy` (version 1.24 ou supérieure) pour le calcul numérique
- `scikit-learn` (version 1.3 ou supérieure) pour la vectorisation TF-IDF et le clustering
- `nltk` (version 3.8 ou supérieure) pour le prétraitement textuel
- `matplotlib` et `seaborn` pour la visualisation
- `jupyter` pour l'exécution du notebook

5. Installation

L'installation du projet se déroule en trois étapes. Il est recommandé d'utiliser un environnement virtuel Python pour isoler les dépendances.

5.1 Création de l'environnement virtuel

Depuis la racine du projet, créer et activer un environnement virtuel Python :

```
python3 -m venv venv
source venv/bin/activate
```

Sous Windows, la commande d'activation est :

```
venv\Scripts\activate
```

5.2 Installation des dépendances

Les dépendances Python sont installées à partir du fichier `requirements.txt` :

```
pip install -r requirements.txt
```

5.3 Téléchargement des ressources NLTK

Le module de prétraitement utilise les stopwords et le lemmatiseur WordNet de NLTK. Ces ressources doivent être téléchargées une première fois :

```
python -c "import nltk; nltk.download('stopwords'); nltk.download('wordnet')"
```

Ce téléchargement est également effectué automatiquement lors de l'importation du module `preprocessing.py`, mais il est préférable de le lancer manuellement pour vérifier que tout fonctionne correctement.

5.4 Données

Le fichier principal `postings.csv` doit être placé dans le dossier `Données/` à la racine du projet. Ce fichier n'est pas inclus dans le dépôt en raison de sa taille. Il peut être obtenu depuis le dataset *LinkedIn Job Postings (2023)* sur Kaggle¹. Les fichiers secondaires du dataset (sous-dossiers `jobs/` et `mappings/`) doivent également être placés dans le dossier `Données/`.

6. Démarrage rapide

Pour les utilisateurs pressés, voici les commandes minimales à exécuter depuis la racine du projet pour obtenir les résultats. L'environnement virtuel et les dépendances doivent avoir été installés au préalable (section 5).

```
# 1. Activer l'environnement virtuel
source venv/bin/activate

# 2. Lancer le notebook
jupyter notebook notebooks/01_clustering_offres_emploi.ipynb

# 3. Dans le notebook : exécuter toutes les cellules (Cell > Run All)
```

Alternativement, pour une exécution non interactive qui reproduit les résultats sans ouvrir le navigateur :

```
make run
```

¹<https://www.kaggle.com/datasets/arshkon/linkedin-job-postings>

À l'issue de l'exécution (environ 5 minutes), les résultats sont visibles dans les cellules de sortie du notebook et les graphiques sont enregistrés dans le dossier `outputs/`.

7. Organisation du projet

Le projet est organisé selon l'arborescence suivante.

```
.
+- Données/
| +- postings.csv # Dataset principal (~124 000 offres)
| +- compagnies/ # Données sur les entreprises (non exploité)
| +- jobs/
| | +- job_industries.csv # Secteurs par offre (validation externe)
| | +- job_skills.csv # Compétences par offre (validation externe)
| | +- benefits.csv # Avantages sociaux (non exploité)
| | +- salaries.csv # Salaires (non exploité)
| +- mappings/
| +- industries.csv # Table de référence des secteurs
| +- skills.csv # Table de référence des compétences
+- notebooks/
| +- 01_clustering_offres_emploi.ipynb # Notebook principal
+- src/
| +- preprocessing.py # Module de nettoyage textuel
| +- __init__.py
+- outputs/ # Graphiques générés par le notebook
+- reports/ # Notes et rapport
+- docs/ # Documentation utilisateur (ce document)
+- requirements.txt # Dépendances Python
+- README.md
```

Le dossier `Données/` contient le fichier CSV principal (`postings.csv`) ainsi que des fichiers secondaires répartis dans les sous-dossiers `jobs/` et `mappings/`. Le fichier principal sert au clustering textuel. Les fichiers `job_industries.csv` et `job_skills.csv`, associés à leurs tables de référence respectives, sont utilisés pour la validation externe des clusters. Les fichiers relatifs aux entreprises (`compagnies/`), aux salaires et aux avantages sociaux ne sont pas exploités car ils ne contribuent pas au clustering textuel ou présentent une couverture insuffisante.

Le dossier `notebooks/` contient le notebook Jupyter principal qui constitue le point d'entrée du projet. C'est dans ce notebook que l'ensemble du pipeline est exécuté, de l'exploration des données à l'interprétation des clusters.

Le dossier `src/` contient le module Python `preprocessing.py`, qui regroupe les fonctions de nettoyage textuel utilisées par le notebook. Ce module est importé automatiquement par le notebook et ne nécessite pas d'intervention de l'utilisateur.

Le dossier `outputs/` contient les graphiques produits lors de l'exécution du notebook. Ces fichiers sont générés automatiquement et peuvent être régénérés en relançant le notebook.

8. Utilisation du projet

8.1 Lancement du notebook

Le projet s'utilise principalement via le notebook Jupyter. Depuis la racine du projet, avec l'environnement virtuel activé :

```
jupyter notebook notebooks/01_clustering_offres_emploi.ipynb
```

Le notebook s'ouvre dans le navigateur. Il suffit ensuite d'exécuter les cellules dans l'ordre, de haut en bas. L'exécution complète prend environ 5 minutes.

8.2 Déroulement du pipeline

Le notebook est organisé en sections numérotées qui correspondent aux étapes successives du pipeline.

La première section charge le fichier `postings.csv` et effectue un échantillonnage aléatoire de 30 000 offres. La graine aléatoire est fixée à 42 pour garantir la reproductibilité des résultats. Les descriptions trop courtes (moins de 100 caractères) sont filtrées.

La deuxième section explore le corpus : statistiques descriptives, répartition des longueurs de texte, niveaux d'expérience disponibles.

La troisième section applique le prétraitement textuel. Le titre de chaque offre est concaténé avec sa description, puis le texte est nettoyé (suppression du HTML, du boilerplate juridique, des stopwords, lemmatisation). Cette étape est la plus longue du pipeline. Les détails du prétraitement sont décrits dans la documentation technique.

La quatrième section transforme les textes nettoyés en vecteurs numériques par TF-IDF. Les paramètres du vectoriseur sont configurables dans la cellule correspondante du notebook (voir la section 8.3).

La cinquième section exécute le clustering K-Means pour différentes valeurs de k (de 2 à 15), puis retient $k = 8$ comme nombre final de clusters. Une comparaison avec l'algorithme

DBSCAN est également réalisée, mais K-Means est retenu car plus adapté aux données textuelles.

La sixième section analyse et interprète les clusters obtenus : taille de chaque groupe, termes les plus représentatifs, exemples d'offres proches du centroïde, visualisation en deux dimensions, et validation externe par croisement avec les secteurs d'activité et les compétences LinkedIn.

8.3 Modification des paramètres

Le notebook contient des constantes qui peuvent être ajustées par l'utilisateur. La variable `RANDOM_SEED` (valeur actuelle : 42) contrôle la reproductibilité de l'échantillonnage et du clustering. La variable `N_OFFRES` (valeur actuelle : 30 000) définit la taille de l'échantillon. Le nombre de clusters retenu est défini par la variable `CHOSEN_K` (valeur actuelle : 8). Les paramètres du vectoriseur TF-IDF (`max_features=10 000`, `max_df=0.85`, `min_df=50`, plage de n-grammes (1,2)) sont configurables dans la cellule correspondante.

9. Description des données en entrée

Le fichier principal est `postings.csv`, situé dans le dossier `Données/`. Il contient environ 124 000 offres d'emploi LinkedIn en anglais. Chaque ligne correspond à une offre d'emploi.

Les champs exploités par le pipeline sont les suivants.

- **title** : titre du poste (environ 31 caractères en moyenne). Ce champ est toujours renseigné.
- **description** : description complète de l'offre (environ 3 750 caractères en moyenne). Ce champ est toujours renseigné.
- **formatted_experience_level** : niveau d'expérience requis. Ce champ est renseigné dans environ 76% des cas et sert uniquement à l'analyse croisée après le clustering.

D'autres champs sont présents dans le fichier (`company_name`, `job_id`, etc.) mais ne sont pas utilisés pour le clustering. Le champ `skills_desc` a été exclu car il est vide dans environ 90% des cas.

9.1 Fichiers secondaires utilisés pour la validation

Le projet exploite également quatre fichiers secondaires pour la validation externe des clusters.

- `jobs/job_industries.csv` : associe chaque offre (`job_id`) à un identifiant de secteur d'activité. Couverture d'environ 98.8% des offres.
- `mappings/industries.csv` : table de correspondance entre les identifiants de secteur et leur nom complet (422 secteurs).
- `jobs/job_skills.csv` : associe chaque offre (`job_id`) à une catégorie de compétence. Couverture d'environ 98.6% des offres.
- `mappings/skills.csv` : table de correspondance entre les abréviations et les noms complets des 35 catégories de compétences.

Ces fichiers ne sont pas utilisés pour le clustering lui-même. Ils servent uniquement à vérifier, après le clustering, que les groupes obtenus à partir du texte correspondent à des catégories métier cohérentes.

9.2 Fichiers non exploités

Les fichiers relatifs aux entreprises (`companies.csv`, `company_industries.csv`, `company_specialities.csv`, `employee_counts.csv`) n'ont pas été retenus car le clustering porte sur le contenu des offres, pas sur les caractéristiques des entreprises. Les fichiers `benefits.csv` (couverture de 23%) et `salaries.csv` (couverture de 29%) ont été écartés en raison de leur couverture insuffisante.

10. Description des sorties

L'exécution du notebook produit plusieurs fichiers graphiques dans le dossier `outputs/`. Ces fichiers sont enregistrés automatiquement au format PNG.

- `distribution_longueurs.png` : histogrammes de la longueur des titres et des descriptions avant nettoyage.
- `distribution_tokens.png` : distribution du nombre de tokens par document après nettoyage.
- `elbow_silhouette.png` : courbe du coude (inertie) et scores silhouette pour différentes valeurs de `k`.
- `taille_clusters.png` : diagramme en barres de la taille de chaque cluster.
- `clusters_2d.png` : projection en deux dimensions des clusters par TruncatedSVD.
- `experience_par_cluster.png` : répartition des niveaux d'expérience par cluster.

- `industries_par_cluster.png` : heatmap croisant les clusters avec les 10 principaux secteurs d'activité LinkedIn.
- `skills_par_cluster.png` : heatmap croisant les clusters avec les 10 principales catégories de compétences.

En plus des graphiques, le notebook affiche dans ses cellules de sortie les termes les plus représentatifs de chaque cluster, des exemples d'offres proches du centroïde et le score silhouette global et par cluster.

11. Comment lire les résultats

Cette section explique comment interpréter les principales sorties du projet.

11.1 Tableau récapitulatif des clusters

Le notebook affiche un tableau associant chaque cluster à un numéro, une taille et ses cinq termes les plus représentatifs. Les termes dominants permettent d'identifier le thème de chaque cluster. Par exemple, un cluster dont les termes dominants sont *patient*, *care*, *nurse* correspond au domaine de la santé. Le thème interprétatif est une lecture humaine, pas une étiquette automatique.

11.2 Graphiques de validation

Les heatmaps `industries_par_cluster.png` et `skills_par_cluster.png` permettent de vérifier si les clusters textuels correspondent à des catégories professionnelles réelles. Une concentration de couleur forte à l'intersection d'un cluster et d'un secteur ou d'une compétence indique une bonne correspondance. Par exemple, si le cluster santé est fortement associé au secteur *Hospitals and Health Care*, cela confirme la qualité du regroupement.

11.3 Score silhouette

Le score silhouette mesure la cohérence interne des clusters. Un score proche de 1 indique un cluster très compact. Dans le cas du clustering textuel haute dimension, les scores sont généralement faibles (autour de 0.01), ce qui ne remet pas en cause la qualité des résultats. Le pourcentage de documents avec un score positif dans chaque cluster est un indicateur plus parlant : un pourcentage élevé (supérieur à 80 %) indique un cluster cohérent.

11.4 Projection 2D

Le graphique `clusters_2d.png` montre une projection simplifiée des clusters dans un plan. Cette visualisation donne une idée de la séparation entre les groupes, mais la réduction de 10 000 dimensions à 2 entraîne une perte d'information importante. Des clusters qui se chevauchent visuellement peuvent être bien séparés dans l'espace original.

12. Exemple de workflow

Voici le déroulement complet pour reproduire les résultats du projet.

1. Cloner ou télécharger le projet.
2. Placer le fichier `postings.csv` dans le dossier `Données/`.
3. Créer et activer l'environnement virtuel Python.
4. Installer les dépendances avec `pip install -r requirements.txt`.
5. Télécharger les ressources NLTK.
6. Ouvrir le notebook avec `jupyter notebook notebooks/01_clustering_offres_emploi.ipynb`.
7. Exécuter toutes les cellules dans l'ordre.
8. Consulter les graphiques générés dans le dossier `outputs/`.
9. Lire les résultats affichés dans les cellules de sortie du notebook pour interpréter les clusters.

À l'issue de l'exécution, le notebook affiche un tableau récapitulatif associant chaque cluster à un thème interprétatif, ses termes dominants et sa taille. Les huit clusters obtenus correspondent à des familles de métiers identifiables : emplois physiques, maintenance, commerce de détail, services généraux, santé, informatique, direction commerciale et management.

13. Limites et précautions

Plusieurs points méritent d'être connus avant d'utiliser ce projet.

- Le corpus est entièrement en anglais. Le pipeline de prétraitement (stopwords, lemmatiseur) n'est pas transposable à d'autres langues sans adaptation.
- Un des huit clusters fonctionne comme groupe résiduel et rassemble les offres qui ne correspondent clairement à aucune spécialité. C'est un comportement normal de

K-Means.

- Le fichier `postings.csv` pèse environ 500 Mo et le pipeline nécessite au moins 8 Go de mémoire vive.
- Le score silhouette global est faible, ce qui est attendu en clustering textuel haute dimension. L'interprétation qualitative et la validation externe sont de meilleurs indicateurs de la qualité des résultats.

Pour une discussion plus approfondie des limites méthodologiques, consulter le rapport de projet.

14. Dépannage

14.1 Erreur `ModuleNotFoundError`

Cette erreur signifie que les dépendances ne sont pas installées ou que l'environnement virtuel n'est pas activé. Vérifier que le `venv` est bien activé (`source venv/bin/activate`) puis relancer `pip install -r requirements.txt`.

14.2 Erreur `NLTK Resource not found`

Le module de prétraitement télécharge automatiquement les ressources NLTK au premier lancement. Si le téléchargement échoue (par exemple en l'absence de connexion internet), exécuter manuellement :

```
python -c "import nltk; nltk.download('stopwords'); nltk.download('wordnet')"
```

14.3 Erreur `FileNotFoundError` pour `postings.csv`

Le fichier de données principal n'est pas inclus dans le dépôt. Il faut le télécharger depuis Kaggle et le placer dans le dossier `Données/` à la racine du projet (voir section 5).

14.4 Le notebook est très lent ou plante

L'étape de prétraitement textuel est la plus consommatrice en temps et en mémoire. Si le notebook est trop lent, il est possible de réduire la taille de l'échantillon en modifiant la variable `N_OFFRES` dans le notebook (voir section 8.3). Vérifier également que la machine dispose d'au moins 8 Go de mémoire vive.

14.5 Les graphiques ne s'affichent pas

Les graphiques sont enregistrés automatiquement dans le dossier `outputs/`. S'ils n'apparaissent pas dans le notebook, vérifier que le dossier `outputs/` existe à la racine du projet. Le créer si nécessaire avec `mkdir -p outputs`.

15. Conclusion

Cette documentation présente les éléments nécessaires pour comprendre, installer et utiliser le projet de clustering d'offres d'emploi. Le pipeline, accessible via un notebook Jupyter unique, permet de reproduire l'intégralité du traitement en quelques minutes.

Le projet illustre la mise en œuvre concrète d'un pipeline de fouille de données textuelles sur un cas d'usage réel. Malgré les limitations liées à TF-IDF et K-Means, les clusters obtenus sont interprétables et correspondent à des familles de métiers cohérentes, ce que confirme le croisement avec les métadonnées structurées du dataset LinkedIn.

Pour toute question sur le fonctionnement du projet ou sur les choix méthodologiques, le fichier `docs/rapport/IED-M1-Rapport-Maxime_BRONNY-19009314.pdf` contient des notes détaillées sur chaque étape du pipeline et les décisions prises au cours du développement.